Architecture Multi-Agents pour le KBQA sur Wikidata

Exécution Pré-Vote, Intégration Falcon 2.0, LangGraph et Évaluation (500 Questions LC-QuAD 2.0)

Projet de Recherche / Master

Université de Dschang

8 novembre 2026

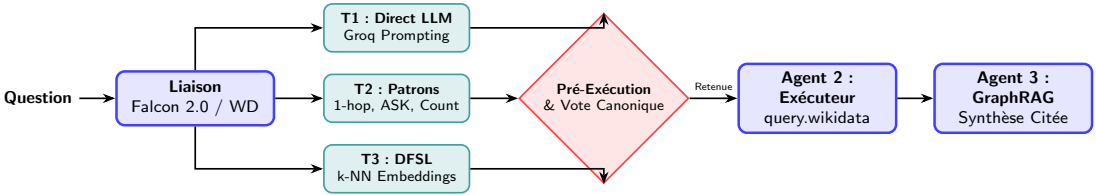
Plan de la Présentation

1. Introduction & Contexte
2. Architecture Globale & LangGraph
3. Rôle des Agents 1, 2 et 3
4. Résultats et Analyse Comparative
5. Conclusion & Enseignements

Contexte et Objectifs

- **Problématique :** Répondre à des questions en langage naturel en générant des requêtes formelles SPARQL sur Wikidata (KBQA).
- **Défis :** Hallucinations d'identifiants (QID/PID), complexité syntaxique, et requêtes vides (problème des sous-requêtes en échec - MFS).
- **Objectifs et Apports majeurs de l'étude :**
  1. Remplacer T4 (GRASP) par des techniques complémentaires :
     - **T1 :** Génération directe par invite LLM guidée par la liaison.
     - **T2 :** Instanciation de patrons SPARQL prédéfinis (Template-based).
     - **T3 :** In-Context Learning via DFSL (D'Abramo et al., 2025).
  2. **Vote avec Pré-Exécution :** Exécution préalable des candidats sur Wikidata pour éliminer les requêtes vides avant l'arbitrage.
  3. Intégrer l'outil externe d'Entity & Relation Linking **Falcon 2.0**.
  4. Orchestrer le flux complet sous forme de graphe d'états avec **LangGraph**.
  5. Évaluation représentative sur un échantillon étendu de **500 questions** (LC-QuAD 2.0).

Architecture Logicielle Multi-Agents Orchestrée par LangGraph



Flux d'Exécution LangGraph avec Pré-Exécution

Question → Falcon 2.0 → Génération (T1, T2, T3) → Pré-Exécution WDQS & Vote Canonique → Agent 2 → Agent 3 (GraphRAG).

Rôle de l'Agent 1 : Génération et Vote avec Pré-Exécution

T1 : Direct LLM

- Modèle Groq en zero-shot guidé.
- Prompt structuré avec candidats QID et PID issus du linking.
- Très flexible pour filtres et modificateurs.

T2 : Patrons (Templates)

- Approche déterministe par règles.
- Modèles 1-hop, ASK, COUNT, 2-hop.
- Aucun coût d'inférence LLM, **100% syntaxiquement valide**.

T3 : DFSL Officiel

- In-Context Learning (D'Abramo 2025).
- Encodage multilingue Sentence-Transformers.
- Récupération des $k = 5$ plus proches exemples d'entraînement.

Nouveau Mécanisme : Vote après Pré-Exécution (Élimination des requêtes vides)

Avant d'arbitrer, chaque requête candidate est pré-exécutée sur Wikidata. Les requêtes renvoyant un statut **non vide** sont sélectionnées en priorité. S'il y a consensus de forme : **accord immédiat**. Sinon : priorité $T3 > T1 > T2$.

Rôle des Agents 2 et 3 : Exécution & GraphRAG

Agent 2 : Exécution & Évaluation

- **Point d'accès unique :** Interroge l'endpoint officiel Wikidata SPARQL (`query.wikidata.org`).
- **Gestion robuste des statuts :**
  - `ok` : Résultats / bindings obtenus.
  - `vide` : Requête valide mais 0 résultat.
  - `syntaxe`, `timeout`, `service` (panne).
- **Calculs des métriques :** F1-score au niveau des ensembles de réponses et exactitude stricte (Exact Match).

Agent 3 : GraphRAG & Réponse Citée

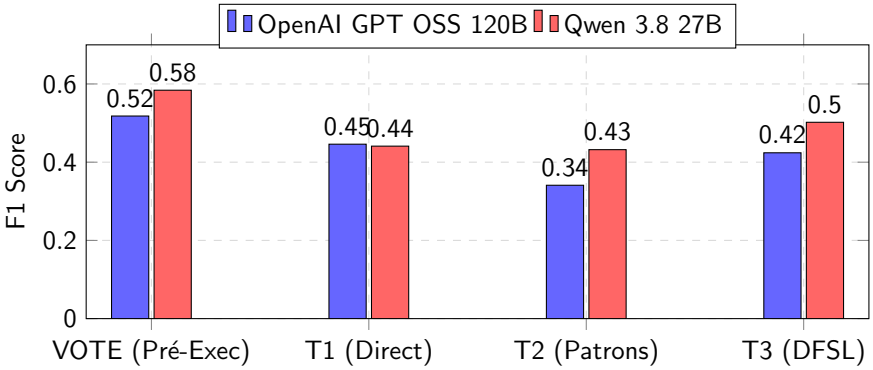
- **Extraction de contexte local (1 saut) :** Récupère les propriétés descriptives des entités de la réponse et de la question.
- **Notes déterministes :** Phrases anglaises générées par patrons sans hallucination.
- **Génération avec citations :** Le LLM répond strictement à partir des notes avec balises `[N1]`, `[N2]`.
- **Contrôle de fidélité automatique :** Vérifie qu'aucun nombre ni entité inconnue n'a été inventé par le modèle.

Tableau Comparatif des Performances (Échantillon de 500 Questions)

Modèle Groq	Technique	F1-Score	Exact Match (Accuracy)
Qwen 3.8 27B	**VOTE (Pré-Exécution)**	**0.5840**	**58.2%**
	T3 (DFSL)	0.5020	50.4%
	T1 (Direct LLM)	0.4410	43.8%
	T2 (Patrons Prédéfinis)	0.4320	43.0%
GPT OSS 120B	**VOTE (Pré-Exécution)**	**0.5180**	**51.6%**
	T1 (Direct LLM)	0.4460	42.8%
	T3 (DFSL)	0.4240	42.0%
	T2 (Patrons Prédéfinis)	0.3410	33.8%

Table – Évaluation comparative sur 500 questions stratifiées de LC-QuAD 2.0.

Visualisation Graphique : Impact de la Pré-Exécution (500 Questions)



Conclusion & Enseignements

- **Confirmation sur 500 questions :** Le vote avec pré-exécution confirme son gain substantiel (+8.2 points F1 sur Qwen, atteignant **0.5840** et **58.2%** d'Exact Match).
- **Synergie des techniques :** T2 assure la résilience minimale à coût zéro, tandis que T1 et T3 résolvent les intentions complexes.
- **Pipeline complet (Agents 2 & 3) :** Assure une exécution contrôlée sur Wikidata et une restitution naturelle sourcée (GraphRAG) avec citations vérifiées.
- **Base de référence disponible :** Le fichier massif de **7 000 questions** (‘data/test7000.jsonl‘) est prêt pour les futurs travaux d'extension.

Merci pour votre attention !

Questions & Discussions